



***INSTITUTO POLITÉCNICO
NACIONAL***

ESCOM

Bases de datos

***Funes Santamaría José Roberto
Martínez Ruiz Cesar Javier***

***Práctica 02-Ejercicio 03
Grupo: 3IV1***

Territorial Information Retrieval from Heterogeneous Open Data through the

Construction of a Data Warehouse for Water Management in Mexico City

¿QUE PROBLEMA ABORDA Y PORQUE ES IMPORTANTE?

La Ciudad de México enfrenta una crisis hídrica crítica caracterizada por sobreexplotación de mantos acuíferos, fugas masivas en la red y alta densidad poblacional. Aunque el Sistema de Aguas de la Ciudad de México (SACMEX) publica datos abiertos de consumo, estos se encuentran dispersos en archivos planos sin esquema relacional formal, sin versionado, sin metadatos suficientes y sin herramientas analíticas o geoespaciales para su consulta.

Por qué importa: Permite transformar datos gubernamentales estáticos y heterogéneos en un repositorio analítico consultable. Facilita que ciudadanos, investigadores, periodistas y autoridades identifiquen patrones de consumo excesivo o atípico, comparen el uso doméstico frente al comercial y realicen diagnósticos territoriales basados en evidencia para una gestión transparente y equitativa del agua.

¿DE DONDE PROVIENEN LOS DATOS, EN QUE FORMATO ESTABAN Y QUE TUVO QUE HACERSE PARA PODER USARLOS?

Origen de los datos: Portal de Datos Abiertos de la CDMX (ADIP), recurso oficial de SACMEX: *Consumo Agua (1er Semestre 2019)*. Además, se integraron series meteorológicas diarias de *Open-Meteo* (licencia CC BY 4.0) y la cartografía base de *OpenStreetMap* (ODbL).

Formato original: Archivos CSV planos y heterogéneos con 71,102 registros a nivel manzana correspondientes a los tres primeros bimestres de 2019.

Proceso de preparación (Pipeline ETL):

Extracción: Ingesta de los archivos CSV de SACMEX mediante scripts en Python y SQL.

Validación y Limpieza: Descarte determinista de 216 registros (0.30% del total) que presentaban la etiqueta literal "NA" en los campos de colonia y alcaldía. Ningún registro se perdió por formatos de fecha o medidas corruptas, conservando 70,886 filas limpias (99.70%).

Carga a Staging y Dimensiones: Carga temporal (comando COPY) y extracción de valores únicos hacia dimensiones conformadas (`dim_tiempo`, `dim_ubicacion`, `dim_indice_des`). Se calcularon los centroides espaciales (latitud/longitud) para 1,553 pares alcaldía-colonia a partir de 22,930 coordenadas únicas.

Población de Hechos: Cruce mediante inner joins hacia las tablas de hechos (`fact_consumo_agua` y `fact_clima`).

Mapeo R2RML y Grafo RDF: Conversión declarativa del esquema estrella a un grafo de conocimiento RDF validado bajo el estándar W3C RDF Data Cube y GeoSPARQL (declarando el predicado `agua:nearbyWithin1500m`).

Exportación Estática: Generación de archivos JSON/GeoJSON para una interfaz web serverless publicada en GitHub Pages.

¿COMO SE MODELO LA INFORMACIÓN QUE ENTIDADES O DIMENSIONES SE IDENTIFICARON, QUE HECHOS SE MIDEN Y COMO SE RELACIONAN?

Arquitectura: Esquema dimensional en estrella (Star Schema) en PostgreSQL, proyectado declarativamente hacia un grafo de conocimiento RDF.

- **Tablas de Hechos (Fact Tables):**
 - **fact_consumo_agua** (70,886 registros): Grano a nivel de una manzana por bimestre facturado. Mide el volumen total consumido en metros cúbicos (m^3), diferenciando consumo doméstico, no doméstico/mixto y número de tomas.
 - **fact_clima** (181 registros): Grano diario con mediciones meteorológicas (temperatura, precipitación).
- **Dimensiones Conformadas:**
 - **dim_tiempo** (181 registros): Granularidad diaria (fecha, año, bimestre). Permite consultar hechos de consumo y clima conjuntamente.
 - **dim_ubicacion** (1,553 registros): Pares únicos alcaldía-colonia con coordenadas de su centroide geográfico.
 - **dim_indice_des** (4 registros): Niveles ordinales del índice de desarrollo socioeconómico de SACMEX (Popular, Bajo, Medio, Alto).
- **Relaciones:** Claves foráneas desde las tablas de hechos hacia las dimensiones (surrogate keys). En la capa RDF, las observaciones (`qb:Observation`) se vinculan a dimensiones (`qb:DimensionProperty`) y medidas (`qb:MeasureProperty`), resolviendo la adyacencia territorial como navegación en grafo.
-

¿QUE PREGUNTAS CONCRETAS PUEDE RESPONDER EL SISTEMA RESULTANTE?

- ¿Cuáles son las alcaldías con mayor volumen total de consumo de agua? (Cuauhtémoc lidera con 18.4M m^3 y Miguel Hidalgo con 14.5M m^3).
- ¿Qué proporción del agua se destina a comercio/industria frente a uso habitacional? (En Cuauhtémoc el 32.5% es no doméstico, frente a solo 20.3% en Gustavo A. Madero).
- ¿Qué colonias vecinas (adyacentes a menos de 1,500 metros) presentan consumos elevados que superan la media de su alcaldía? (Consulta topológica en GeoSPARQL).
- ¿Cómo varía el consumo a lo largo de los bimestres del semestre y si coincide con épocas de sequía o lluvias?
- ¿Cuál es la relación entre el nivel de desarrollo socioeconómico y el consumo? (Las colonias de índice Alto muestran en promedio mayor consumo que las de índice Bajo).
- ¿Qué zonas presentan anomalías estadísticas críticas ($\text{SA}_g > 3$ desviaciones estándar respecto a su propia alcaldía) para priorizar inspecciones de consumo atípico o fugas?

¿QUE LIMITACIONES RECONOCEN LOS AUTORES Y QUE TRABAJO FUTURO PROPONEN?

Limitaciones reconocidas:

- *Ventana temporal acotada:* Solo abarca el primer semestre de 2019 (tres bimestres) sin actualizaciones posteriores por parte del portal oficial (última subida en febrero 2023).
 - *Aproximación por centroides:* Las colonias se modelan como puntos y no como polígonos vectoriales oficiales, impidiendo usar predicados topológicos exactos como fronteras compartidas (`geo:sfTouches`).
 - *Módulo de anomalías exploratorio:* No detecta fugas en tiempo real al carecer de sensores físicos o reportes ciudadanos de fugas; solo calcula desviaciones estadísticas ($\$z\$$ -score local) evaluadas con perturbaciones sintéticas.
 - *No es un indicador per cápita:* El consumo agregado no refleja el consumo por persona, ya que alcaldías comerciales atraen población flotante.
 - *Carga en cliente:* La versión estática requiere que el navegador descargue y procese 3.9 MB de datos completos.
- **Trabajo futuro propuesto:**
 - Materializar el grafo en un Triple Store persistente con un endpoint SPARQL público.
 - Incorporar polígonos vectoriales oficiales de colonias para análisis espacial estricto.
 - Interoperar con otros conjuntos de datos abiertos de la ciudad (Linked Open Data).
 - Reevaluar algoritmos de detección (como Isolation Forest) cuando existan datos reales etiquetados de fugas.
 - Extender el enfoque hacia movilidad, calidad del aire y riesgo sísmico.

A Dimensional Data Warehouse for Geospatial Monitoring of Municipal Public Works, with an Evolution Path Toward a Lakehouse Architecture

¿QUE PROBLEMA ABORDA Y PORQUE ES IMPORTANTE?

Problema: La falta de transparencia, trazabilidad histórica y auditoría en la gestión de obras públicas en municipios mexicanos. Las áreas de obras públicas operan con hojas de cálculo desvinculadas, expedientes en papel y fotografías dispersas, lo cual imposibilita auditar cambios presupuestales, detectar retrasos a tiempo o permitir que los ciudadanos supervisen los proyectos de infraestructura comunitaria.

Por qué importa: La obra pública municipal concentra gran parte del presupuesto local y es vulnerable a irregularidades, obras fantasma y sobrecostos. El artículo demuestra que un municipio rural o pequeño puede implementar un sistema analítico auditable y robusto utilizando servicios gestionados económicos (PostgreSQL/Supabase y almacenamiento de objetos S3) sin incurrir en los prohibitivos costos de plataformas empresariales (como Databricks o Snowflake).

¿DE DONDE PROVIENEN LOS DATOS, EN QUE FORMATO ESTABAN Y QUE TUVO QUE HACERSE PARA PODER USARLOS?

- **Origen de los datos:** Contextualizado en el municipio de Temascaltepec, Estado de México (64,844 habitantes en 55 comunidades). Debido a restricciones legales de privacidad sobre expedientes reales no publicados, se generó un escenario sintético riguroso y multi-semilla (Faker) con 1,247 obras públicas y un presupuesto acumulado de \$127.4 millones de pesos.
- **Formato original:** Datos estructurados tabulares (montos, coordenadas, contratos, fechas) y evidencia binaria no estructurada (fotografías de avance de obra en JPG/PNG y documentos oficiales de supervisión en PDF).
- **Proceso de preparación e ingeniería:**
 - *Arquitectura en capas:* Ingesta web en HTML5/JS y API REST en Flask/Python (56 rutas en 9 blueprints).
 - *Sincronización operacional-analítica por triggers:* En lugar de un proceso ETL por lotes externo, se diseñaron 12 triggers en la base de datos PostgreSQL: 8 triggers sincronizan las dimensiones (gestionando versiones SCD 2 en tiempo real) y 4 triggers insertan eventos en la tabla de hechos de auditoría.
 - *Almacenamiento de objetos desacoplado:* Subida directa de fotos y PDFs a Cloudflare R2 con particionamiento tipo Hive (`works/{id}/reports/{year}-{month}/`). Los metadatos y URLs públicas se almacenan en el Data Warehouse mediante un patrón de compensación (borrado best-effort en caso de fallo).
 - *Georreferenciación:* Posicionamiento de obras en las 55 comunidades vía OpenStreetMap con un desplazamiento determinista de 150m para evitar colisiones visuales en el mapa.

¿COMO SE MODELO LA INFORMACIÓN QUE ENTIDADES O DIMENSIONES SE IDENTIFICARON, QUE HECHOS SE MIDEN Y COMO SE RELACIONAN?

Modelo: Esquema dimensional en estrella con 2 tablas de hechos y 10 dimensiones, clasificadas según el manejo de cambios históricos (Kimball SCD):

- **Tablas de Hechos:**
 - **fact_audit_events:** Grano a nivel de un evento atómico e inmutable de auditoría (17 tipos de eventos: creación, modificación, cambio de estado, subida de foto, cambio de presupuesto, etc.). Particionada por rangos de año. Mide importes modificados, porcentajes de avance y banderas de auditoría.
 - **fact_work_monthly:** Grano a nivel de una obra por mes calendario (instantánea periódica). Mide presupuesto total, costo acumulado, saldo remanente, avance físico (%), avance financiero (%), número de reportes/fotos y días de retraso (*slippage*).
- **10 Dimensiones:**
 - *5 Dimensiones SCD Tipo 2 (guardan historial con effective_date, expiration_date, is_current):* **dim_work** (obra), **dim_region** (comunidad/geografía), **dim_company** (contratista), **dim_staff** (supervisores/personal) y **dim_budget** (partida presupuestal).

- *3 Dimensiones SCD Tipo 1 (se sobrescriben, solo estado actual):* `dim_source` (fuente de financiamiento), `dim_citizen` (ciudadano) y `dim_proposal` (propuesta ciudadana).
- *2 Dimensiones SCD Tipo 0 (catálogos estáticos fijos):* `dim_time` (tiempo) y `dim_event_type` (tipo de evento).
- **Vistas Analíticas (OLAP):** 6 vistas estándar en SQL: obras retrasadas (`v_delayed_works`), alertas de auditoría (`v_audit_alerts`), trazabilidad histórica SCD2 (`v_work_traceability`), participación ciudadana (`v_citizen_participation`), presupuesto ejecutado (`v_budget_executed`) y detección de anomalías (`v_anomalies_detection`).

¿QUE PREGUNTAS CONCRETAS PUEDE RESPONDER EL SISTEMA RESULTANTE?

- ¿Cuál era el presupuesto autorizado vigente el día exacto en que se autorizó un pago, antes de cualquier modificación posterior? (Resuelta mediante `dim_budget` SCD 2).
- Si una obra cambió de contratista a la mitad, ¿qué porcentaje de avance y pagos corresponden legalmente a la empresa original y cuáles a la nueva? (Resuelta mediante `dim_company` SCD 2).
- ¿Qué obras presentan inconsistencias críticas entre el avance físico y el financiero? (Criterio C3: avance físico < 30% con avance financiero > 80%, posible indicador de desvío).
- ¿Cuáles son las obras con desfases temporales extremos que superan los 120 días de retraso respecto a su fecha planeada? (Criterio C2).
- ¿Cómo se distribuye la inversión pública por habitante en cada comunidad en comparación con su nivel de rezago social?
- ¿Cuáles son las propuestas de infraestructura ciudadana más votadas en cada región?
- ¿Dónde se ubica geográficamente cada obra y cuál es su evidencia fotográfica de avance físico validada por los supervisores?

¿QUE LIMITACIONES RECONOCEN LOS AUTORES Y QUE TRABAJO FUTURO PROPONEN?

- **Limitaciones reconocidas:**
 - *Datos sintéticos:* La evaluación se realizó con datos simulados y no con expedientes de obras reales, debido a la falta de datos abiertos en municipios rurales.
 - *Despliegue no alojado en backend:* La persistencia online es estática en GitHub Pages; el backend con PostgreSQL/Flask debe ser levantado localmente mediante Docker.
 - *Arquitectura centrada en almacén (no Lakehouse puro):* Cloudflare R2 solo actúa como repositorio de archivos binarios, no como un lago con tablas analíticas abiertas consultables directamente.

- *Falta de atomicidad en subida de evidencia:* La API y el bucket R2 no forman una transacción ACID conjunta; una falla entre el registro en base de datos y el bucket puede dejar objetos huérfanos.
- *Bajo desempeño en detección de sobrecostos:* El módulo C1-C3 obtuvo 0.46 de precisión y 0.35 de recall; falla al detectar sobreprecios relativos porque compara el costo absoluto contra la media del periodo (castiga obras grandes honestas).
- *Seguridad básica:* La validación de roles en la API viaja en encabezados y los tokens de sesión ciudadana no tienen caducidad automática.
- **Trabajo futuro propuesto:**
 - Evolucionar hacia un Lakehouse completo adoptando formatos abiertos como Apache Iceberg o Parquet sobre R2, consultables con motores ligeros como DuckDB o Trino.
 - Implementar modelos de visión artificial (Computer Vision) para verificar y clasificar automáticamente el avance de la obra a partir de las fotografías.
 - Publicar el esquema como ontología OWL y proyectar los datos al estándar internacional OC4IDS (Open Contracting for Infrastructure Data Standard).
 - Adoptar esquemas de votación cuadrática para proteger las prioridades de comunidades minoritarias.

Cuando México tiembla: La historia contada por los datos

¿QUE PROBLEMA ABORDA Y PORQUE ES IMPORTANTE?

Problema: México está en el Cinturón de Fuego del Pacífico y sobre cinco placas tectónicas, por lo que cerca del 70 % del país está expuesto a riesgo sísmico. El Servicio Sismológico Nacional (SSN) publica datos detallados de los sismos desde 1900, pero son muy técnicos, visualmente poco amigables y difíciles de manejar. Esto complica el análisis y la investigación, y no permite relacionarlos fácilmente con datos demográficos y económicos.

Por qué importa:

- Los sismos no pueden pronosticarse con certeza, así que contar con datos confiables (magnitud, profundidad, ubicación) y entenderlos es clave.
- Zonas muy pobladas como el Valle de México y Guadalajara son vulnerables, y los autores señalan que la mayoría de la población ignora el riesgo sísmico del país.
- Transforma datos técnicos en un sistema web interactivo y gratuito, útil para planeación territorial, educación y concientización, e investigación científica.

¿DE DONDE PROVIENEN LOS DATOS, EN QUE FORMATO ESTABAN Y QUE TUVO QUE HACERSE PARA PODER USARLOS?

Origen de los datos:

- SSN: catálogo con más de 300 000 sismos registrados en México desde 1900.
- INEGI: Censo de Población y Vivienda 2020 y Censos Económicos (el texto dice 2019, pero la referencia cita CE 2024).
- Cartografía base: OpenStreetMap.

Formato original: tres archivos CSV (uno del SSN y dos del INEGI).

Proceso de preparación:

- Extracción: descarga manual de los CSV desde los sitios del SSN y del INEGI.
- Validación y limpieza: un programa en Python busca campos vacíos, coordenadas inconsistentes y formatos incompatibles, y elimina los registros inválidos. Los autores aclaran que las bases están bien construidas, pero aun así contienen registros incorrectos. El artículo no reporta cuántos registros se descartaron.
- Generación de SQL: el programa produce un archivo SQL con todos los datos validados.
- Carga a PostgreSQL: el SQL se ejecuta para crear la base de datos con estructura de almacén de datos (*data warehouse*).
- Capa de servicios: PHP 8 con servidor Apache atiende las consultas a la base de datos.
- Presentación: HTML5, CSS3, Bootstrap y JavaScript para la interfaz, y OpenStreetMap para los mapas.
- Despliegue: Docker Compose con dos contenedores (base de datos y servidor web PHP), distribuidos mediante un repositorio público en GitHub.

¿COMO SE MODELO LA INFORMACIÓN QUE ENTIDADES O DIMENSIONES SE IDENTIFICARON, QUE HECHOS SE MIDEN Y COMO SE RELACIONAN?

Arquitectura: estructura de *data warehouse* en PostgreSQL que integra sismos, población y economía. El texto no describe el esquema en detalle. Lo que sigue se obtiene de la Figura 6 (captura de PostgreSQL en Docker) y de los reportes mostrados, y es una interpretación.

- Tabla de hechos:
 - `fact_impacto_sismos_imputed`: relaciona los sismos con su impacto. Por los reportes, mide magnitud, profundidad, número de sismos, población potencialmente afectada (personas en zonas cercanas a los epicentros) y producción económica. El artículo no declara su grano.
- Dimensiones:
 - `dim_sismos`: eventos sísmicos (ubicación, magnitud, profundidad).
 - `dim_tiempo`: fecha del evento (por los filtros y gráficas, permite consultar por año y mes).

- `dim_zonas`: zonas o localidades geográficas.
- `dim_economia`: información económica del INEGI.
- Relaciones: la tabla de hechos se vincula con las dimensiones, cruzando dónde y cuándo ocurrió un sismo con la población y la economía de las zonas cercanas. El artículo no detalla llaves ni atributos de cada tabla.

¿QUE PREGUNTAS CONCRETAS PUEDE RESPONDER EL SISTEMA RESULTANTE?

- ¿Qué sismos de magnitud 2 o mayor ocurrieron y dónde? (Mapa interactivo: verde de 2 a 3.9, amarillo de 4 a 5.9, rojo de 6 o más).
- ¿Qué localidades densamente pobladas (50 000 habitantes o más) están cerca de los epicentros?
- ¿Qué alcance en distancia tuvo un sismo y qué localidades afectó directamente? (Mapa de calor).
- ¿Cuántos sismos hubo por estado, año o mes, y cuál fue el de mayor impacto? (Ejemplo de Jalisco 2017: 47 sismos, 5,497,428 personas potencialmente afectadas y un sismo máximo de 5.6).
- ¿Cómo se distribuyen las magnitudes y cómo se relacionan magnitud con profundidad, y población afectada con magnitud?
- ¿Aumentó o disminuyó la actividad sísmica a lo largo de los 125 años de datos?
- ¿Qué resultados arroja un reporte personalizado con filtros por periodo, magnitud, localidad, profundidad, habitantes o producción económica?
- ¿Qué zonas están en peligro, qué rutas de evacuación son seguras y qué planes de acción conviene diseñar ante réplicas? (Uso en gestión gubernamental).

¿QUE LIMITACIONES RECONOCEN LOS AUTORES Y QUE TRABAJO FUTURO PROPONEN?

Limitaciones reconocidas:

- Calidad de los datos: las bases de origen tienen registros incorrectos o inconsistentes que debieron depurarse.
- Complejidad de implementación: puede ser difícil para usuarios con poco dominio de las herramientas. Se mitigó con Docker Compose, que solo requiere tener Docker y ejecutar un comando.
- Dependencia del formato técnico de los datos del SSN, que motivó el proyecto.

Trabajo futuro propuesto:

- Habilitar visualizaciones en 3D.
- Incorporar más fuentes de datos oficiales.
- Integrar el sistema con plataformas de alerta temprana.

